Visualización de la Información - Tarea 5

11 de Marzo del 2022

Andrés Urbano Guillermo Gerardo

El hundimiento del Titanic es uno de los naufragios más infames de la historia. Esta es la descripción de las variables de nuestro conjunto de datos.

Caracteristica	Descripcion
pclass	Clase del pasajero
survived	Indica si sobrevivio (0 = No; 1 = Sí)
name	Nombre
sex	Una variable categorica de hombre y mujer
age	edad en años
sibsp	Número de hermanos/cónyuges a bordo
parch	Número de padres/niños a bordo
ticket	Numero de ticket
fare	Tarifa de pasajero
cabin	Cabina
embarked	El lugar donde embarcaron (Cherbourg, Queenstowny Southampton)
boat	Bote salvavidas
body	Número de identificación del cuerpo
home.dest	Inicio/Destino

[390]:
```
data = pd.read_csv('data/titanic3.csv')
data.tail()
```

[390]:

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest
1304	3	0	Zabour, Miss. Hileni	female	14.5	1	0	2665	14.4542	NaN	C	NaN	328.0	NaN
1305	3	0	Zabour, Miss. Thamine	female	NaN	1	0	2665	14.4542	NaN	C	NaN	NaN	NaN
1306	3	0	Zakarian, Mr. Mapriededer	male	26.5	0	0	2656	7.2250	NaN	C	NaN	304.0	NaN
1307	3	0	Zakarian, Mr. Ortin	male	27.0	0	0	2670	7.2250	NaN	C	NaN	NaN	NaN
1308	3	0	Zimmerman, Mr. Leo	male	29.0	0	0	315082	7.8750	NaN	S	NaN	NaN	NaN

i) ¿Cuántos cuerpos fueron encontrados?

Para conocer la cantidad de cuerpos encontrados dado nuestro conjunto datos debemos de filtrar la columna body.

[391]:
```
body_found = data.body.dropna()
print(f"Cantidad de cuerpos encontrados: {len(body_found)}")
```

```
Cantidad de cuerpos encontrados: 121
```

Tambien podriamos conocer la cantidad de personas que sobrevieron y que en clase pertenecian:

[392]:
```
survived_people = data[data.survived == 1]
no_survived_people = data[data.survived == 0]
print(f"Total de personas encontradas {len(survived_people)}")
```

```
Total de personas encontradas 500
```

[393]:
```
sns.catplot(data=data, kind="bar", x="sex", y="survived", hue="pclass")
```

[393]:
```
<seaborn.axisgrid.FacetGrid at 0x7f5a8fe9f220>
```

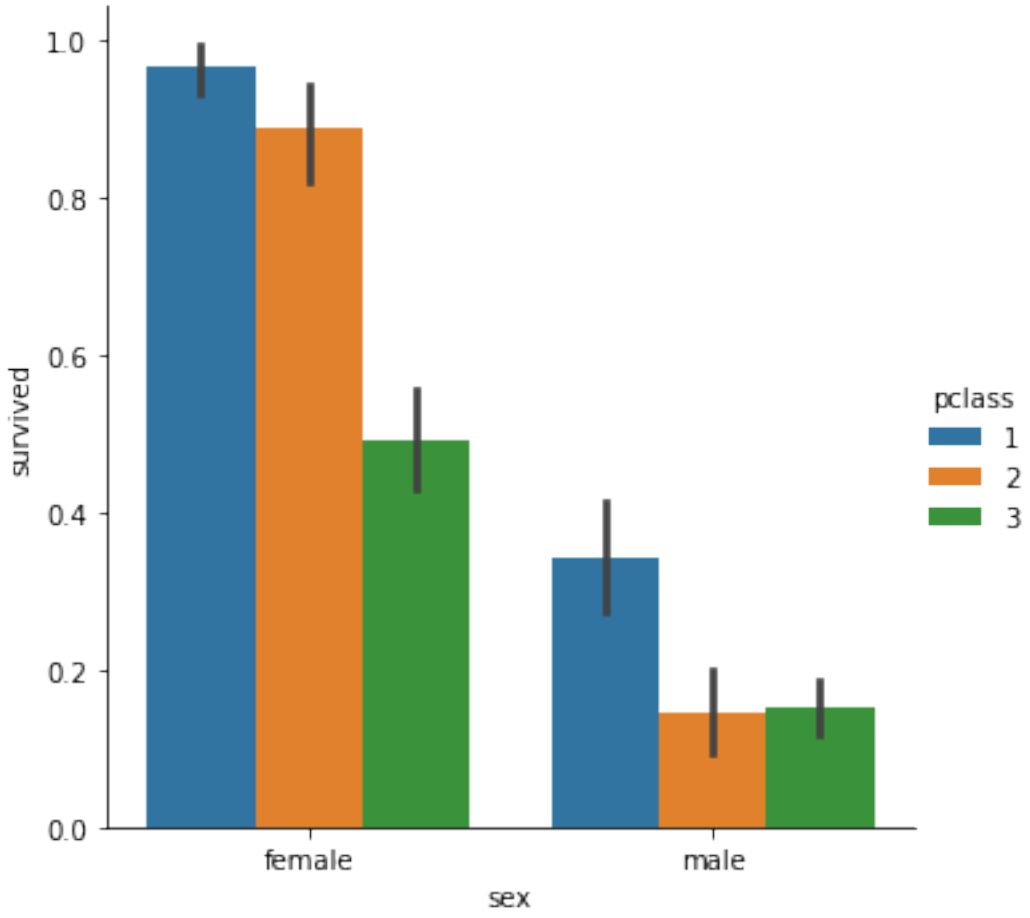

ii) ¿Cuántos de ellos fueron hombres mayores a cuarenta años?

[394]:
```
#  Filtramos por edad y sexo
male_40 = data[(data.age > 40) & (data.sex == "male")]
sns.displot(data=male_40, x="age")
```

[394]: <seaborn.axisgrid.FacetGrid at 0x7f5a90a020b0>

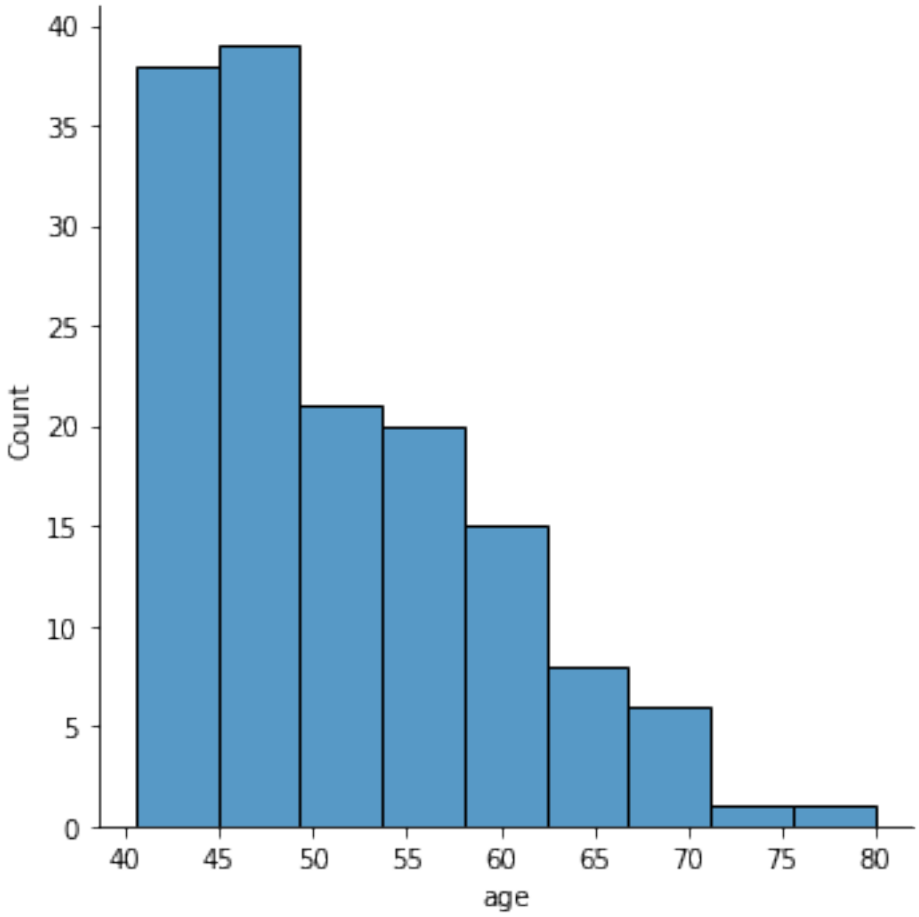

iii) ¿Cuantas mujeres desaparecieron entre las edades de 15 a 35 años? Para determniar las mujeres que desaparecieron es encontrar la cantidad de personas que no sobrevivieron en el accidente:

[395]:
```
missing_woman = data[(data.sex == "female") & (data.age >= 15) & (data.age <=␣
↪35) & (data.survived == 0)]
print(f"Total de mujeres desaparecidas {len(missing_woman)}")
```

```
Total de mujeres desaparecidas 55
```

[396]:
```
sns.catplot(x="pclass", y="age", data=missing_woman)
```

[396]:
```
<seaborn.axisgrid.FacetGrid at 0x7f5a90120c40>
```

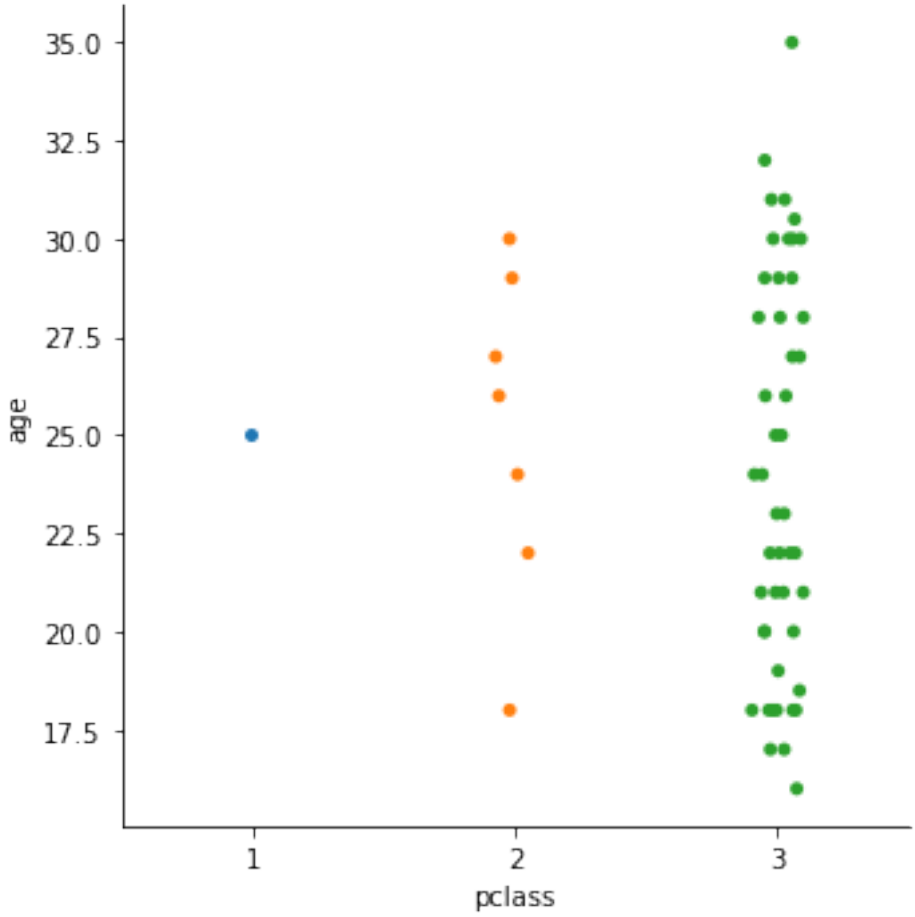

Por otra parte, tambien podemos conocer las mujeres que no encontraron sus cuerpos.

[397]:
```
not_found_woman = missing_woman.body.fillna("Cuerpos no encontrados")
not_found_woman = not_found_woman[not_found_woman == "Cuerpos no encontrados"]
print(f"Mujeres que desaparecieron entre las edades de 15 a 35 años: ␣
 ↪{len(not_found_woman)}")
```

```
Mujeres que desaparecieron entre las edades de 15 a 35 años:  51
```

iv) ¿Cuantos hombres mayores a 20 años sobrevivieron?

[398]:
```
men_20 = data[(data.age > 20) & (data.survived == 1)]
print(f"Total de hombres mayores de 20 que sobrevivieron: {len(men_20)}")
```

```
Total de hombres mayores de 20 que sobrevivieron: 313
```

[399]:
```
sns.displot(men_20, x="age", y="pclass")
```

[399]:
```
<seaborn.axisgrid.FacetGrid at 0x7f5a90cbe530>
```

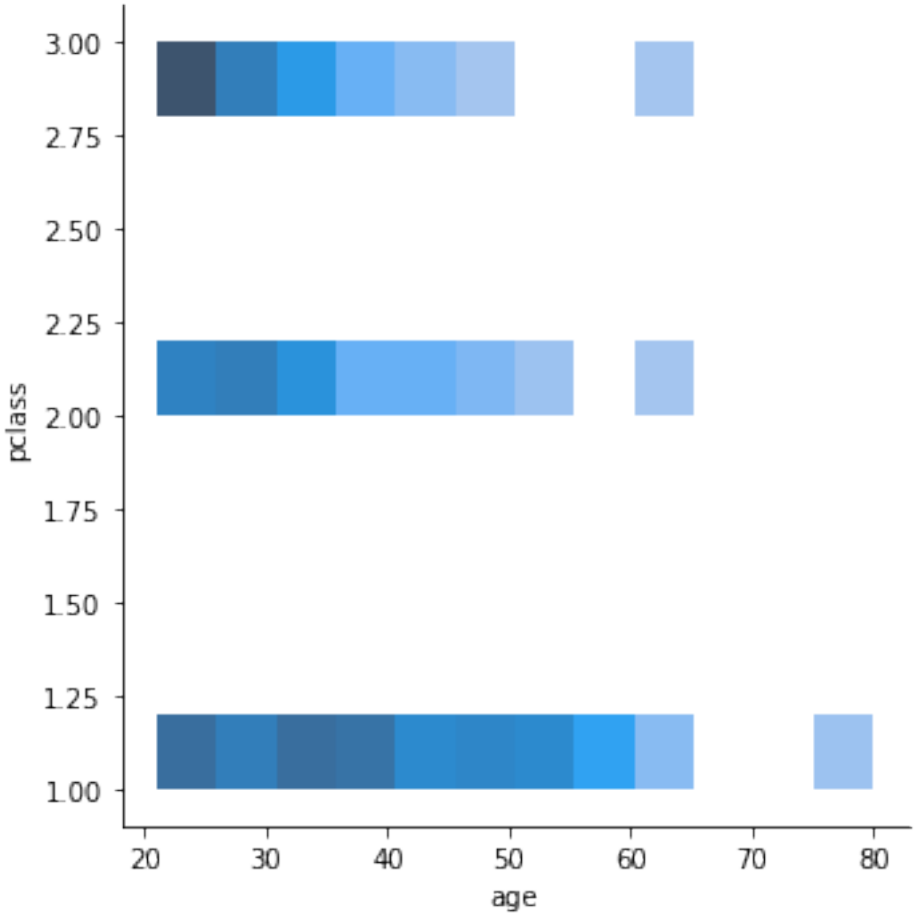

v) ¿Cuantas mujeres menores a 25 años sobrevivieron?.

[400]:
```
woman_25 = data[(data.age > 25) & (data.survived == 1)]
print(f"Total de mujeres mayores de 25 que sobrevivieron: {len(men_20)}")
```

```
Total de mujeres mayores de 25 que sobrevivieron: 313
```

[401]:
```
sns.displot(woman_25, x="age")
```

[401]:
```
<seaborn.axisgrid.FacetGrid at 0x7f5a8ff1c880>
```

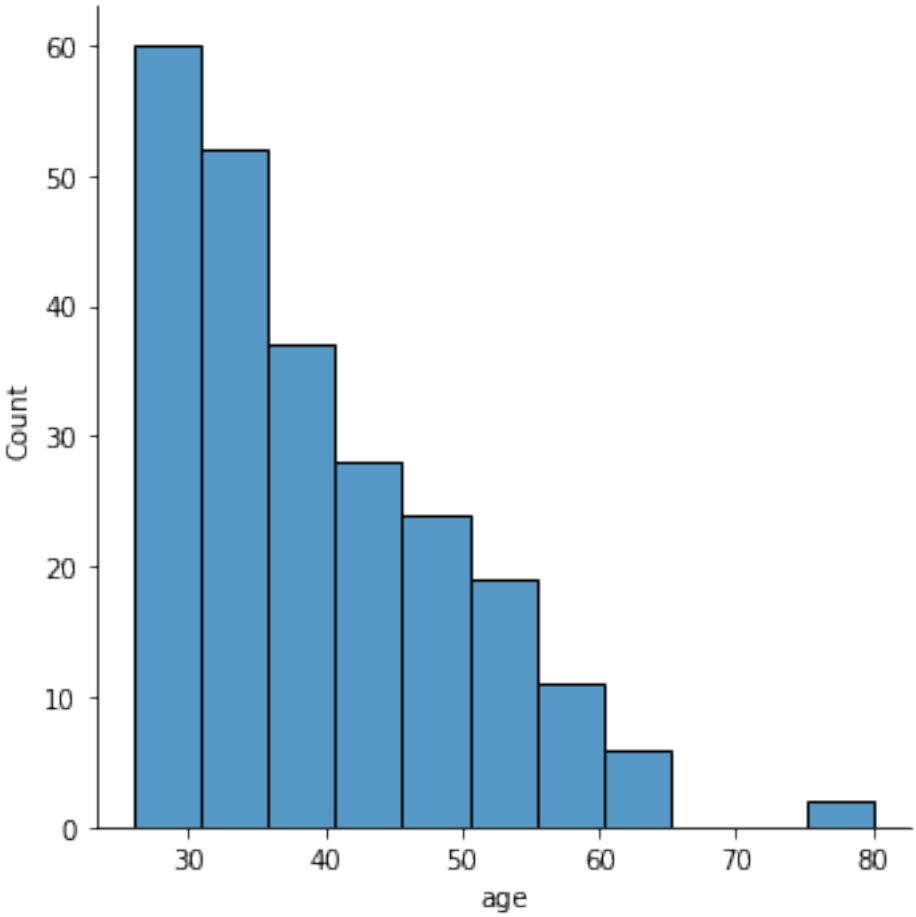

Además, Genere una copia del conjunto de datos y rellene los datos faltantes (NA's) con un valor de 0 en el caso de datos numéricos usados como identificador la palabra "desconocido" en el caso de datos tipo cadena de caracteres y en el caso de variables numéricas use el promedio de los valores de esa columna (p.ej., la edad y la tarifa)

[402]:
```
# Generamos  una copia del conjunto de datos originales
data_cp = data.copy()
# Ver el número de elementos faltantes
print(data_cp.isnull().sum())
```

```
pclass          0
survived        0
name            0
sex             0
age           263
sibsp           0
parch           0
ticket          0
fare            1
```

```
cabin        1014
embarked        2
boat          823
body         1188
home.dest     564
dtype: int64
```

[403]:
```
def fill_NA(data, columns_names, values):
    """Rellena los NA del dataframe original"""
    for column_name, value in zip(columns_names, values):
        # Por paso de referencia actualizaremos el dataframe
        data[column_name] = data[column_name].fillna(value)
```

[404]:
```
# Para variables numericas 0
columns_names = ["body", "boat"]
fill_NA(data_cp, colums_names, [0,0])
data_cp[columns_names].head(5)
# "desconocido" en el caso de datos tipo cadena de caracteres
columns_names = ['home.dest', 'embarked', 'cabin']
fill_NA(data_cp, columns_names, ["desconocido"]*3)
# promedio de los valores para age y fare
columns_names = ['age', 'fare']
age_mean = data.age.mean()
fare_mean = data.fare.mean()
fill_NA(data_cp, columns_names, [age_mean, fare_mean])
```

[405]:
```
# Vemos nuevamente el número de elementos faltantes
print(data_cp.isnull().sum())
```

```
pclass       0
survived     0
name         0
sex          0
age          0
sibsp        0
parch        0
ticket       0
fare         0
cabin        0
embarked     0
boat         0
body         0
home.dest    0
dtype: int64
```

[406]:
```
data_cp.tail()
```

[406]:
```
      pclass  survived                          name     sex        age  sibsp  \
1304       3         0       Zabour, Miss. Hileni  female  14.500000      1
1305       3         0      Zabour, Miss. Thamine  female  29.881135      1
1306       3         0  Zakarian, Mr. Mapriededer    male  26.500000      0
1307       3         0        Zakarian, Mr. Ortin    male  27.000000      0
1308       3         0         Zimmerman, Mr. Leo    male  29.000000      0

      parch  ticket     fare        cabin embarked boat   body    home.dest
1304      0    2665  14.4542  desconocido        C    0  328.0  desconocido
1305      0    2665  14.4542  desconocido        C    0    0.0  desconocido
1306      0    2656   7.2250  desconocido        C    0  304.0  desconocido
1307      0    2670   7.2250  desconocido        C    0    0.0  desconocido
1308      0  315082   7.8750  desconocido        S    0    0.0  desconocido
```

0.1 Normalización y Estandarización

Finalmente, de los campos "age" y "fare" agregue columnas al conjunto de datos qué contengan los valores normalizados.

[407]:
```
data_cp['age_norm'] = (data_cp['age'] - data.age.mean() ) / (data.age.std())

data_cp['fare_norm2'] = (data_cp['fare'] - np.min(data.fare)) / (np.max(data.
 ↪fare) - np.min(data.fare))

data_cp.tail(5)
```

[407]:
```
      pclass  survived                          name     sex        age  sibsp  \
1304       3         0       Zabour, Miss. Hileni  female  14.500000      1
1305       3         0      Zabour, Miss. Thamine  female  29.881135      1
1306       3         0  Zakarian, Mr. Mapriededer    male  26.500000      0
1307       3         0        Zakarian, Mr. Ortin    male  27.000000      0
1308       3         0         Zimmerman, Mr. Leo    male  29.000000      0

      parch  ticket     fare        cabin embarked boat   body    home.dest  \
1304      0    2665  14.4542  desconocido        C    0  328.0  desconocido
1305      0    2665  14.4542  desconocido        C    0    0.0  desconocido
1306      0    2656   7.2250  desconocido        C    0  304.0  desconocido
1307      0    2670   7.2250  desconocido        C    0    0.0  desconocido
1308      0  315082   7.8750  desconocido        S    0    0.0  desconocido

      age_norm  fare_norm2
1304 -1.067134    0.028213
1305  0.000000    0.028213
1306 -0.234581    0.014102
1307 -0.199891    0.014102
1308 -0.061133    0.015371
```

b) Utilizando el archivo "movies.csv" construya una o varias funciones qué permitan calcular

una matriz de distancias para los datos numéricos en el dataFrame. La función debe permitir construir la matriz de distancia usando las distancias de Manhattan, Euclideana y de Minkowski (para p igual a 3).

[408]:
```
import plotly as py
import sympy as sp
import plotly.graph_objs as go
from plotly.offline import init_notebook_mode, iplot
from scipy.spatial import distance_matrix
```

[409]:
```
movies_df = pd.read_csv("data/movies.csv", sep=";")
movies_df
```

[409]:

	user_id	star_wars	lord_of_the_rings	harry_potter
0	1	1.2	4.9	2.1
1	2	2.1	8.1	7.9
2	3	7.4	3.0	9.9
3	4	5.6	0.5	1.8
4	5	1.5	8.3	2.6
5	6	2.5	3.7	6.5
6	7	2.0	8.2	8.5
7	8	1.8	9.3	4.5
8	9	2.6	1.7	3.1
9	10	1.5	4.7	2.3

[410]:
```
# Iris-setosa
movies_3d = go.Scatter3d(
                        x = movies_df['star_wars'],
                        y = movies_df['lord_of_the_rings'],
                        z = movies_df['harry_potter'],
                        mode = 'markers',
                        opacity = 0.7,
                        name = "Movies",
                        marker = dict(
                                    size = 5,
                                    color = 'rgba(255,102, 255,0.8)')
)
movies_3d = [movies_3d]
fig_3d = go.Figure(data = movies_3d)
iplot(movies_3d)
```

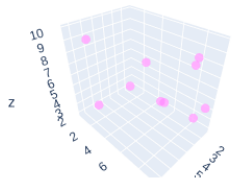

Ya que nuestro conjunto de datos no tiene una adecuada descripción del significado de los valores de las columnas, podemos inferir que cada valor es el grado de satisfaccion de cada usuario respecto a cada pelicual. Viendo nuestro grafico en 3D podemos ver hay usuarios con la misma opinion viendo las distancias entre los puntos, para ser más precicos sacaremos la matriz de distancias.

[411]:
```python
def distancia_euclidiana(a, b):
    """Calcula la distancia euclidiana,

    Arguments
    p - una tupla que será el primer punto.
    q - una tupla que será el segundo punto.

    Return
    Regresa un entero con la distancia entre los puntos.
    """
    # Convertimos los puntos en vectores de numpy
    p1 = np.array(a)
    p2 = np.array(b)
    return np.sqrt(np.sum((p1-p2)**2))

def distancia_manhattan(a, b):
    """Calcula la distancia manhattan,

    Arguments
    p - una tupla que será el primer punto.
    q - una tupla que será el segundo punto.

    Return
    Regresa un entero con la distancia entre los puntos.
    """
    # Convertimos los puntos en vectores de numpy
    p1 = np.array(a)
    p2 = np.array(b)
```

```
    return np.sum(np.abs(p1-p2))

def distancia_minkowski(a, b, p=3):
    """Calcula la distancia minkowski,

    Arguments
    p - una tupla que será el primer punto.
    q - una tupla que será el segundo punto.

    Return
    Regresa un entero con la distancia entre los puntos.
    """
    p1 = np.array(a)
    p2 = np.array(b)
    return np.sum((np.abs(p1-p2)**p)) ** (1/p)
```

[412]:
```
def obtener_matriz_distancias(data, func_dist):
    """Crea una matriz de distancia"""
    matriz_distancias = np.zeros((len(data), len(data)))
    for i, usuario in enumerate(data):
        x1, y1, z1 = usuario
        for j, usuario2 in enumerate(data):
            # Aprovechando las propiedades de simetria e identidad de los␣
 ↪indiscernibles
            if j > i:
                x2, y2, z2 = usuario2
                distancia = func_dist((x1, y1, z1), (x2, y2, z2))
                matriz_distancias[i][j] = distancia
                matriz_distancias[j][i] = distancia

    return matriz_distancias
```

0.2 Distancia Euclidiana

[413]:
```
data = movies_df.iloc[:,1:].values
matriz_dist = obtener_matriz_distancias(data, distancia_euclidiana)
print("\t\t\t Matriz de distancia de euclidines")
display(sp.Matrix(matriz_dist))
```

Matriz de distancia de euclidines

$$\begin{bmatrix}
0 & 6.68505796534331 & 10.1434708063858 & 6.22976725086901 & 3.44963766213207 & 4.7423622 \\
6.68505796534331 & 0 & 7.6223356000638 & 10.3547090736534 & 5.33760245803301 & 4.6346520 \\
10.1434708063858 & 7.6223356000638 & 0 & 8.66602561731732 & 10.779146533933 & 6.0049979 \\
6.22976725086901 & 10.3547090736534 & 8.66602561731732 & 0 & 8.84816365128946 & 6.4761099 \\
3.44963766213207 & 5.33760245803301 & 10.779146533933 & 8.84816365128946 & 0 & 6.1131006 \\
4.74236228055175 & 4.63465209050259 & 6.00499791840097 & 6.47610994347687 & 6.11310068623117 & 0 \\
7.24499827467198 & 0.616441400296897 & 7.62627038597505 & 10.8231233939192 & 5.92199290779717 & 4.9497474 \\
5.04777178564959 & 3.61801050302511 & 10.0104944932805 & 9.95841352826845 & 2.16794833886788 & 5.9874869 \\
3.63318042491699 & 8.0156097709407 & 8.42436941260294 & 3.4828149534536 & 6.7096944788865 & 3.9458839 \\
0.412310562561766 & 6.57875368135941 & 9.77036335045939 & 5.89067059000926 & 3.61247837363769 & 4.4317039
\end{bmatrix}$$

Para comprobar los resultados utilizaremos scipy.spatial.distance_matrix ~~~

p = 1, Manhattan Distance p = 2, Euclidean Distance p = , Chebychev Distance

~~~

[414]:
```
# Comprobacion con scipy.spatial
dist_mat_scpy = distance_matrix(data, data, p=2)
print("\t\t\t Matriz de distancia de euclidines con Scipy")
display(sp.Matrix(dist_mat_scpy))
```

```
Matriz de distancia de euclidines con Scipy
```

$$\begin{bmatrix}
0 & 6.68505796534331 & 10.1434708063858 & 6.22976725086901 & 3.44963766213207 & 4.7423622 \\
6.68505796534331 & 0 & 7.6223356000638 & 10.3547090736534 & 5.33760245803301 & 4.6346520 \\
10.1434708063858 & 7.6223356000638 & 0 & 8.66602561731732 & 10.779146533933 & 6.0049979 \\
6.22976725086901 & 10.3547090736534 & 8.66602561731732 & 0 & 8.84816365128946 & 6.4761099 \\
3.44963766213207 & 5.33760245803301 & 10.779146533933 & 8.84816365128946 & 0 & 6.1131006 \\
4.74236228055175 & 4.63465209050259 & 6.00499791840097 & 6.47610994347687 & 6.11310068623117 & 0 \\
7.24499827467198 & 0.616441400296897 & 7.62627038597505 & 10.8231233939192 & 5.92199290779717 & 4.9497474 \\
5.04777178564959 & 3.61801050302511 & 10.0104944932805 & 9.95841352826845 & 2.16794833886788 & 5.9874869 \\
3.63318042491699 & 8.0156097709407 & 8.42436941260294 & 3.4828149534536 & 6.7096944788865 & 3.9458839 \\
0.412310562561766 & 6.57875368135941 & 9.77036335045939 & 5.89067059000926 & 3.61247837363769 & 4.4317039
\end{bmatrix}$$

0.3 Distancia Manhattan

[415]:
```
matriz_dist = obtener_matriz_distancias(data, distancia_manhattan)
print("\t\t\t Matriz de distancia de manhattan")
display(sp.Matrix(matriz_dist))
```

```
Matriz de distancia de manhattan
```
~~~

$$\begin{bmatrix} 0 & 9.9 & 15.9 & 9.1 & 4.2 & 6.9 & 10.5 & 7.4 & 5.6 & 0.7 \\ 9.9 & 0 & 12.4 & 17.2 & 6.1 & 6.2 & 0.799999999999999 & 4.9 & 11.7 & 9.6 \\ 15.9 & 12.4 & 0 & 12.4 & 18.5 & 9.0 & 12.0 & 17.3 & 12.9 & 15.2 \\ 9.1 & 17.2 & 12.4 & 0 & 12.7 & 11.0 & 18.0 & 15.3 & 5.5 & 8.8 \\ 4.2 & 6.1 & 18.5 & 12.7 & 0 & 9.5 & 6.5 & 3.2 & 8.2 & 3.9 \\ 6.9 & 6.2 & 9.0 & 11.0 & 9.5 & 0 & 7.0 & 8.3 & 5.5 & 6.2 \\ 10.5 & 0.799999999999999 & 12.0 & 18.0 & 6.5 & 7.0 & 0 & 5.3 & 12.5 & 10.2 \\ 7.4 & 4.9 & 17.3 & 15.3 & 3.2 & 8.3 & 5.3 & 0 & 9.8 & 7.1 \\ 5.6 & 11.7 & 12.9 & 5.5 & 8.2 & 5.5 & 12.5 & 9.8 & 0 & 4.9 \\ 0.7 & 9.6 & 15.2 & 8.8 & 3.9 & 6.2 & 10.2 & 7.1 & 4.9 & 0 \end{bmatrix}$$

[416]:
```
dist_mat_scpy = distance_matrix(data, data, p=1)
print("\t\t\t Matriz de distancia de manhattan con Scipy")
display(sp.Matrix(dist_mat_scpy))
```

Matriz de distancia de manhattan con Scipy

$$\begin{bmatrix} 0 & 9.9 & 15.9 & 9.1 & 4.2 & 6.9 & 10.5 & 7.4 & 5.6 & 0.7 \\ 9.9 & 0 & 12.4 & 17.2 & 6.1 & 6.2 & 0.799999999999999 & 4.9 & 11.7 & 9.6 \\ 15.9 & 12.4 & 0 & 12.4 & 18.5 & 9.0 & 12.0 & 17.3 & 12.9 & 15.2 \\ 9.1 & 17.2 & 12.4 & 0 & 12.7 & 11.0 & 18.0 & 15.3 & 5.5 & 8.8 \\ 4.2 & 6.1 & 18.5 & 12.7 & 0 & 9.5 & 6.5 & 3.2 & 8.2 & 3.9 \\ 6.9 & 6.2 & 9.0 & 11.0 & 9.5 & 0 & 7.0 & 8.3 & 5.5 & 6.2 \\ 10.5 & 0.799999999999999 & 12.0 & 18.0 & 6.5 & 7.0 & 0 & 5.3 & 12.5 & 10.2 \\ 7.4 & 4.9 & 17.3 & 15.3 & 3.2 & 8.3 & 5.3 & 0 & 9.8 & 7.1 \\ 5.6 & 11.7 & 12.9 & 5.5 & 8.2 & 5.5 & 12.5 & 9.8 & 0 & 4.9 \\ 0.7 & 9.6 & 15.2 & 8.8 & 3.9 & 6.2 & 10.2 & 7.1 & 4.9 & 0 \end{bmatrix}$$

0.4 Distancia Minkowski

[417]:
```
matriz_dist = obtener_matriz_distancias(data, distancia_minkowski)
print("\t\t\t Matriz de distancia de minkowski")
display(sp.Matrix(matriz_dist))
```

Matriz de distancia de minkowski

$$\begin{bmatrix} 0 & 6.11454916428861 & 8.96172635607764 & 5.5439454576181 & 3.40437729172903 & 4.4665670 \\ 6.11454916428861 & 0 & 6.61551294283105 & 8.91622676181095 & 5.30265679067893 & 4.4478253 \\ 8.96172635607764 & 6.61551294283105 & 0 & 8.20757776606394 & 9.05835740907213 & 5.3980788 \\ 5.5439454576181 & 8.91622676181095 & 8.20757776606394 & 0 & 8.1632351727204 & 5.5000771 \\ 3.40437729172903 & 5.30265679067893 & 9.05835740907213 & 8.1632351727204 & 0 & 5.4021824 \\ 4.46656703819761 & 4.44782539038182 & 5.39807887765857 & 5.50007713390447 & 5.40218247400413 & 0 \\ 6.68384762858978 & 0.601846165480645 & 6.70039353150005 & 9.29843886386646 & 5.90120630318665 & 4.6299557 \\ 4.62955139976453 & 3.44987047052723 & 8.35451128926497 & 9.10987536394208 & 1.99045451433078 & 5.6873114 \\ 3.31750720120221 & 7.19751071354172 & 7.53154711786155 & 3.13884523510554 & 6.61112296419712 & 3.6166155 \\ 0.350339806038672 & 5.99198930956623 & 8.65913810366208 & 5.23095442295267 & 3.60069431052831 & 4.2374578 \end{bmatrix}$$

[418]:
```
dist_mat_scpy = distance_matrix(data, data, p=3)
print("\t\t\t Matriz de distancia de minkowski con Scipy")
```

```
display(sp.Matrix(dist_mat_scpy))
```

Matriz de distancia de minkowski con Scipy

$$\begin{bmatrix} 0 & 6.11454916428861 & 8.96172635607764 & 5.5439454576181 & 3.40437729172903 & 4.4665670 \\ 6.11454916428861 & 0 & 6.61551294283105 & 8.91622676181095 & 5.30265679067893 & 4.4478253 \\ 8.96172635607764 & 6.61551294283105 & 0 & 8.20757776606394 & 9.05835740907213 & 5.3980788 \\ 5.5439454576181 & 8.91622676181095 & 8.20757776606394 & 0 & 8.1632351727204 & 5.5000771 \\ 3.40437729172903 & 5.30265679067893 & 9.05835740907213 & 8.1632351727204 & 0 & 5.4021824 \\ 4.46656703819761 & 4.44782539038182 & 5.39807887765857 & 5.50007713390447 & 5.40218247400413 & 0 \\ 6.68384762858978 & 0.601846165480645 & 6.70039353150005 & 9.29843886386646 & 5.90120630318665 & 4.6299557 \\ 4.62955139976453 & 3.44987047052723 & 8.35451128926497 & 9.10987536394208 & 1.99045451433078 & 5.6873114 \\ 3.31750720120221 & 7.19751071354172 & 7.53154711786155 & 3.13884523510554 & 6.61112296419712 & 3.6166155 \\ 0.350339806038672 & 5.99198930956623 & 8.65913810366208 & 5.23095442295267 & 3.60069431052831 & 4.2374578 \end{bmatrix}$$

Además, Usando los métodos "dendrogram" y "linkage" construya un diagrama en forma de árbol (dendrograma) para el conjunto de datos en "movies.csv". Repita el proceso ahora usando algún esquema de normalización del rango de los datos.

[419]:
```
from scipy.cluster.hierarchy import dendrogram,linkage
```

[420]:
```
Z = linkage(data, "ward")
plt.figure(figsize=(25,10))
plt.title("Dendrograma del clustering jerárquico")
plt.xlabel("Índices de la Muestra")
plt.ylabel("Distancias")
dendrogram(Z, leaf_rotation=90., leaf_font_size=8.0, color_threshold=0.7*180)
plt.show()
```

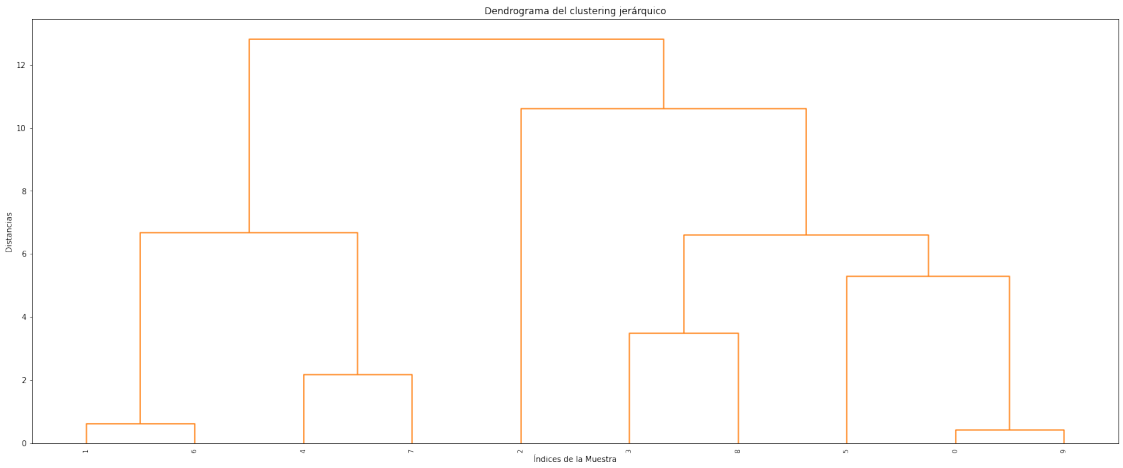

0.4.1 Normalizando los datos.

[421]:
```
data_norm = np.zeros((data.shape[0], data.shape[1]))
for col in range(data.shape[1]):
    data_norm[:,col] = (data[:,col] - data[:,col].mean()) / data[:,col].std()
data_norm
```

[421]:
```
array([[-0.83997603, -0.11622047, -0.98229819],
       [-0.37332268,  0.97761925,  1.03803142],
       [ 2.37474706, -0.7656878 ,  1.7346968 ],
       [ 1.44144035, -1.62025008, -1.08679799],
       [-0.68442492,  1.04598423, -0.80813184],
       [-0.16592119, -0.52641036,  0.55036565],
       [-0.42517305,  1.01180174,  1.24703103],
       [-0.5288738 ,  1.38780914, -0.14629973],
       [-0.11407082, -1.21006019, -0.6339655 ],
       [-0.68442492, -0.18458545, -0.91263165]])
```

[422]:
```
Z = linkage(data_norm, "ward")
plt.figure(figsize=(25,10))
plt.title("Dendrograma del clustering jerárquico")
plt.xlabel("Índices de la Muestra")
plt.ylabel("Distancias")
dendrogram(Z, leaf_rotation=90., leaf_font_size=8.0, color_threshold=0.7*180)
plt.show()
```

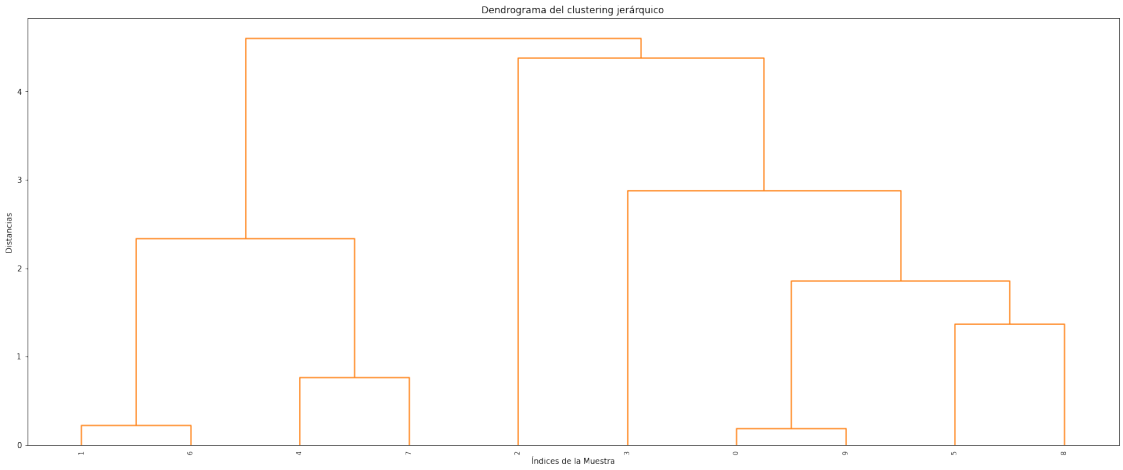

i) ¿Que diferencias puede encontrar en los resultados previos?. Podemos ver que al normalizar las variables los dendrogramas se apachurran en el eje y, es decir, la altura de los rectuangulos se hacen más pequeñas, pero sigue conservando el mismo orden en eje x.

ii) ¿En qué casos resulta importante llevar a cabo un proceso de normalización del rango de datos?. Es muy importante cuando el rango de los datos es superior a los demas, ya que esto

puede sesgar a los dato pequeños.

iii) Consulte los diferentes tipos de distancias que se pueden usar como parámetro en el método "linkage", ¿qué características de los datos se podría basar uno para elegir una determinada distancia?.

Existen otros tipos de enlazamiento, cada uno resuelve soluciones distintas:

- Single linkage: utiliza la distancia más corta entre dos vectores de cada grupo.
- Complete linkage: toma en cuenta la distancia más grande entre dos vectores de cada grupo.
- Average linkage: usa la distancia promedio entre todos los vectores de cada grupo.
- Ward linkage: la distancia es la suma de las diferencias al cuadrado en los grupos.

0.4.2 Referencias

- https://docs.scipy.org/doc/scipy/reference/spatial.distance.html
- https://www.encyclopedia-titanica.org/
- https://www.kaggle.com/vinicius150987/titanic3